

Avaliação dos modelos

Dr. Thadeu Sobral de Souza

Laboratório de Ecologia Espacial e Conservação
Unesp – Rio Claro


Rio Claro - 2017


Ajuste dos modelos

1. Como podemos saber se as predições são boas? Estabelecer a relação entre precisão (*overfitting*), generalização (*underfitting*) e realismo (acurácia);
2. Qual o erro associado a cada modelo?
3. Como eles erram (em qual direção: pres/abs)?


Começamos com um modelo experimental...

**Imagine um alvo cujo ponto central é o valor real
que os modelos deveriam estimar.**






Generalidade vs. Realismo vs. Precisão




Modelo estima uma **alta variância** de valores, dentre eles o “real”.

↓ acurácia
(ruim)



Baixa variância estimada, “no alvo”.
(ideal)


↑ acurácia




Baixa variância estimada, mas “fora do alvo”.

↓ acurácia
(ruim)

No contexto dos ENMs, os
dados de **teste**
estabelecem o **valor real**
que os modelos devem estimar




...no contexto dos ENMs.



- prediz ampla região
- Baixa taxa de acerto, inclusive, com os dados de TREINO

Generalista
(underfitting)

 Espaço Cenopoético disponível

 Nicho Fundamental Existente

 Dados TREINO

 Dados TESTE

 Predição do modelo


Realista
(acurado)

- Prediz corretamente os dados de TESTE


Preciso
(overfitting)

- Predição restrita aos dados de TREINO
- Baixa taxa de acerto com os dados de TESTE

Sobre “*overfitting*” e “*underfitting*”



“OVERFITTING”: caso em que o modelo se especializa nos dados utilizados em seu treinamento, apresentando uma baixa taxa de acerto quando confrontado com novos dados/teste (modelo muito preciso).



“UNDERFITTING”: caso em que o modelo apresenta uma baixa taxa de acerto, mesmo no subconjunto de treinamento (modelo muito generalista).

Como estabelecer os dados de TREINO e TESTE?

Algumas considerações iniciais:

1. Os dados de TREINO e TESTE devem ser independentes;
2. Quanto mais dados de TREINO, melhor será o modelo (i.e. excluir dados de TREINO para obter dados de TESTE, por si só, não é a melhor solução teórica);
3. Sem dados de TESTE não podemos avaliar os modelos.

Soluções teóricas...

**Avaliações
Biológicas**

1. Aplicar o modelo de volta ao campo;

...é o teste mais robusto que se pode fazer com os resultados de modelagem. Avaliar a capacidade do modelo em acertar a presença da espécie em áreas de alta probabilidade de ocorrência e sua ausência em áreas não previstas.

2. Avaliação por especialistas das espécies estudadas.

...inspeção visual, dependente da complacência/opinião do pesquisador, portanto menos robusta que a anterior. Entretanto, ainda é eficiente como uma avaliação biológica (i.e. Um modelo pode ser estatisticamente bem avaliado, mas biologicamente “ruim”).

SOLUÇÕES NADA FÁCEIS!!!

Impossíveis em

alguns casos

(e.g. predição pro futuro).

1. Aplicar o modelo de volta ao campo;

...é o teste mais robusto que se pode fazer com os resultados de modelagem. Avaliar a capacidade do modelo em acertar a presença da espécie em áreas de alta probabilidade de ocorrência e sua ausência em áreas não previstas.

2. Avaliação por especialistas das espécies estudadas.

...inspeção visual e experiência do pesquisador, portanto menos robusta que a anterior. Entretanto, ainda é eficiente como uma avaliação biológica (i.e. Um modelo pode ser estatisticamente bem avaliado, mas biologicamente “ruim”).

Soluções teóricas...

.....dividir as

1. Aplicar o modelo de volta ao campo;

ocorrências

disponíveis em

TREINO e TESTE

2. Avaliação por especialistas das espécies estudadas.

...inspeção visual, dependendo da competência/opinião do pesquisador, portanto menos robusta que a anterior. Entretanto, ainda é eficiente como uma avaliação biológica (i.e. Um modelo pode ser estatisticamente bem avaliado, mas biologicamente “ruim”).

Avaliações
Biológicas

A review of methods for the assessment of prediction errors in conservation presence/absence models

ALAN H. FIELDING¹* AND JOHN F. BELL²

¹*Department of Biological Sciences, the Manchester Metropolitan University, Manchester M1 5GD, UK and* ²*University of Cambridge Local Examinations Syndicate, University of Cambridge, Cambridge, UK*

Date submitted: 18 December 1996 Date accepted: 1 March 1997

Table 1 Data partitioning methods for the allocation of cases to training and testing data sets.

<i>Method</i>	<i>Examples</i>	<i>Notes</i>
Resubstitution	Stockwell (1992) Osborne & Tigar (1992)	Sem particionamento é realizada, os mesmos dados usados para treinamento e testes. Esta tendência para fornecer medidas otimistas de sucesso previsão.
Bootstrapping	Buckland & Elston (1993) Verbyla & Litaitis (1989)	Bootstraps (amostragem com reposição) são usados para avaliar o sucesso da predição. A precisão é geralmente expressa como uma média e confiança limites.
Randomization	Capen <i>et al.</i> (1986)	Amostras aleatórias são obtidos por amostragem, sem reposição. A precisão é geralmente expressa como uma média e confiança limites.
Prospective sampling	Capen <i>et al.</i> (1986) Fielding & Haworth (1995) Morrison <i>et al.</i> (1987)	Um novo exemplo de casos é obtido após o modelo ter sido desenvolvido. Estas podem ser a partir de uma região ou de tempo diferente.
<i>k</i> -fold partitioning	Stockwell (1992)	Os dados estão divididos em <i>k</i> (<i>k</i> > 2) subgrupos, apenas um deles é usado para a fazer a predição do modelo. Os restantes <i>k</i> -1 conjuntos são agrupados para fins de teste. Acuracia é usualmente reportado coo a média e os limites do intervalo de confiança.
<i>Special cases of k-fold partitioning</i>		
Leave-One-Out (L-O-O)	Capen <i>et al.</i> (1986) Osborne & Tigar (1992)	<i>n</i> amostras de 1 caso são testados sequencialmente, os restantes. Leave-one-out
<i>K</i> = 2	Smith (1994)	Dados treinos e testes.

A review of methods for the assessment of prediction errors in conservation presence/absence models

ALAN H. FIELDING^{1*} AND JOHN F. BELL²


¹Department of Biological Sciences, the Manchester Metropolitan University, Manchester M1 5GD, UK and ²University of Cambridge Local Examinations Syndicate, University of Cambridge, Cambridge, UK

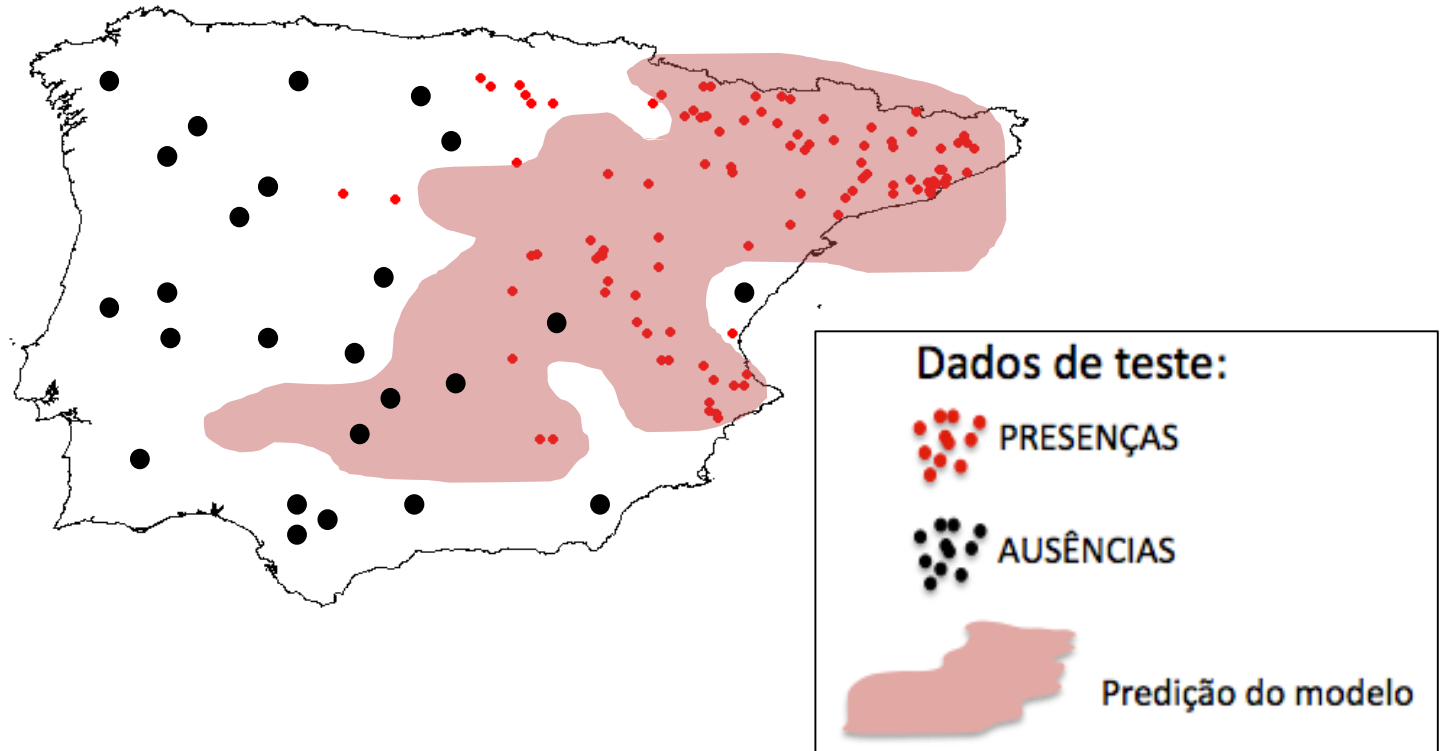
Date submitted: 18 December 1996 Date accepted: 1 March 1997

Table 1 Data partitioning methods for the allocation of cases to training and testing data sets.

Method	Examples	Notes
Resubstitution	Stockwell (1992) Osborne & Tigar (1992)	Sem particionamento é realizada, os mesmos dados usados para treinamento e testes. Esta tendência para fornecer medidas otimistas de sucesso previsão.
Bootstrapping	Buckland & Elston (1993) Verbyla & Litaitis (1989)	Bootstraps (amostragem com reposição) são usados para avaliar o sucesso da predição. A precisão é geralmente expressa como uma média e confiança limites.
Randomization	Capen <i>et al.</i> (1986)	Amostras aleatórias são obtidos por amostragem, sem reposição. A precisão é geralmente expressa como uma média e confiança limites.
Prospective sampling	Capen <i>et al.</i> (1986) Fielding & Haworth (1995) Morrison <i>et al.</i> (1987)	Um novo exemplo de casos é obtido após o modelo ter sido desenvolvido. Estas podem ser a partir de uma região ou de tempo diferente.
Uma combinação das duas técnicas é muito utilizado.		
Special cases of k-fold partitioning		
Leave-One-Out (L-O-O)	Capen <i>et al.</i> (1986) Osborne & Tigar (1992)	n amostras de 1 caso são testados sequencialmente, os restantes. Leave-one-out
K = 2	Smith (1994)	Dados treinos e testes.

Avaliando os ENMs

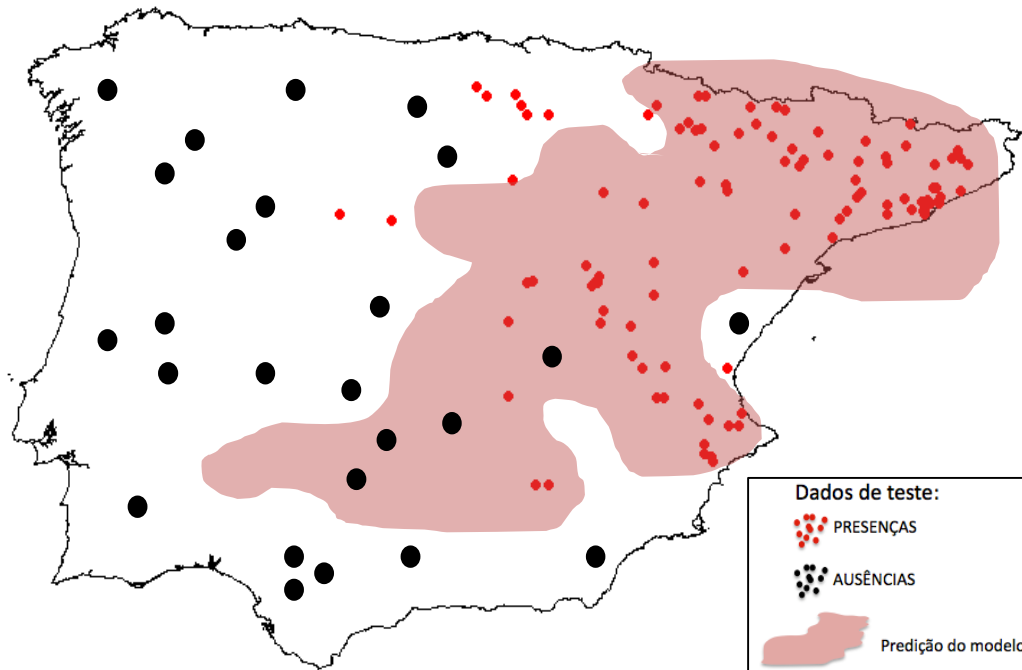




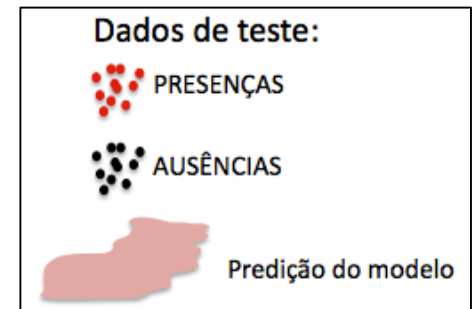
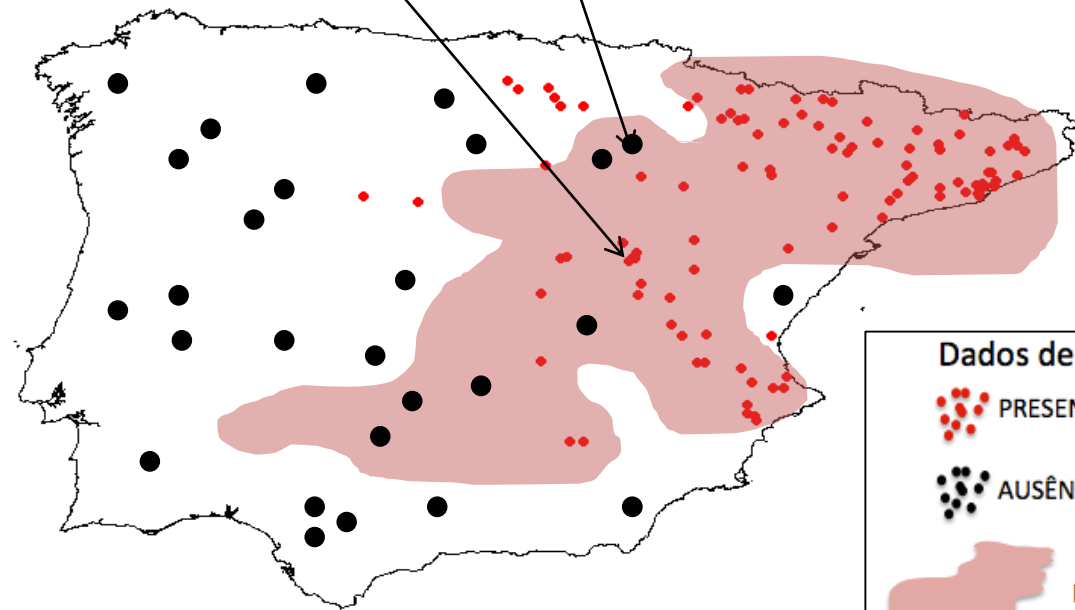
Mapa resultado do proceso de modelagem!!

Matriz de Confusão

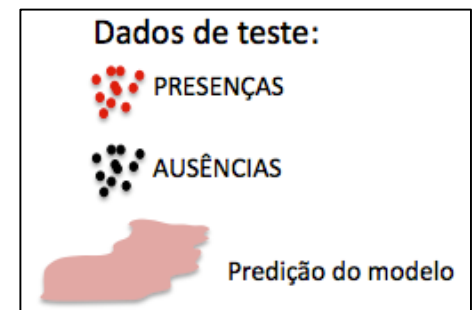
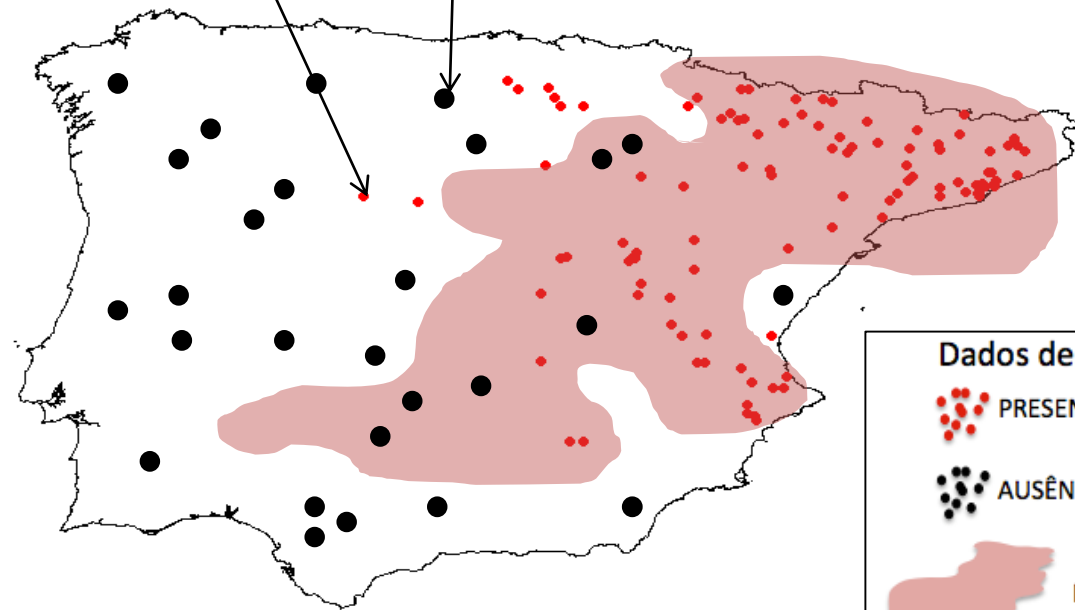
	Presença	Ausência
Presença	a	b
Ausência	c	d

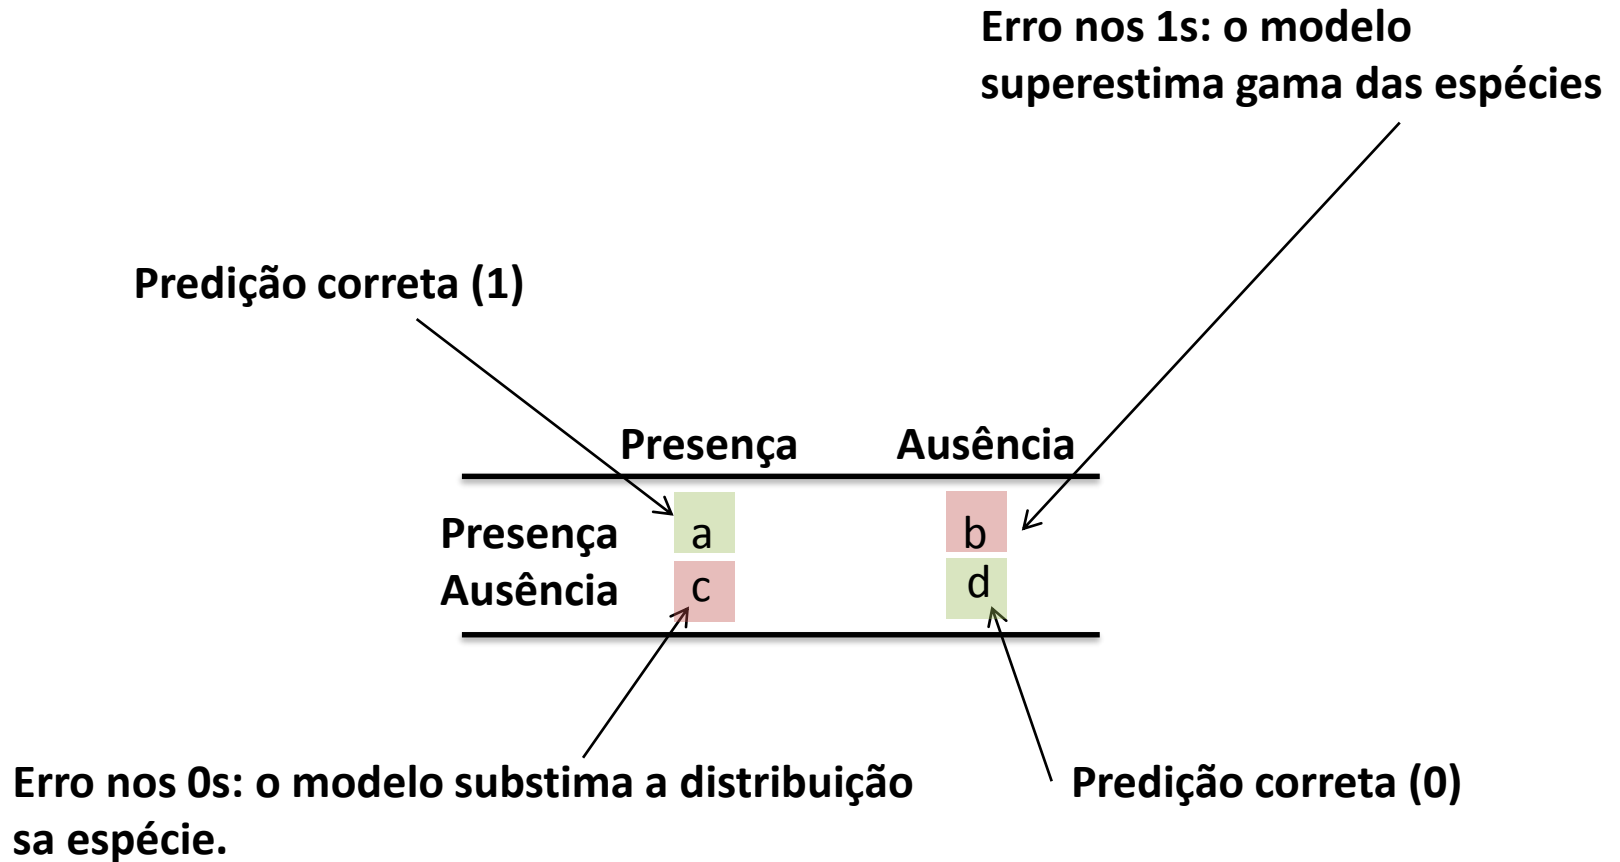


	Presença	Ausência
Presença	a	b
Ausência	c	d



	Presença	Ausência
Presença	a	b
Ausência	c	d

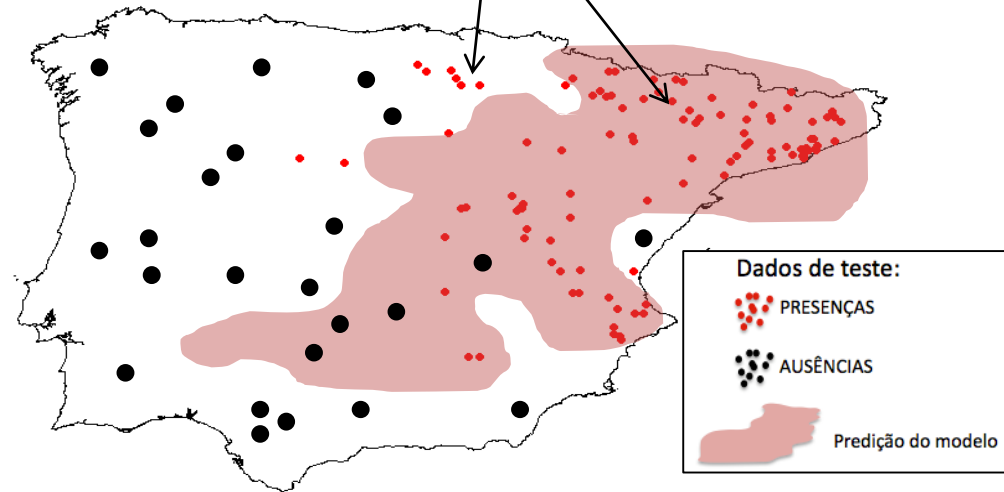




Medindo o ajuste do modelo:

Sensitividade: $\frac{\text{presenças corretas}}{\text{Total de presenças}}$

	Presença	Ausência
Presença	a	b
Ausência	c	d



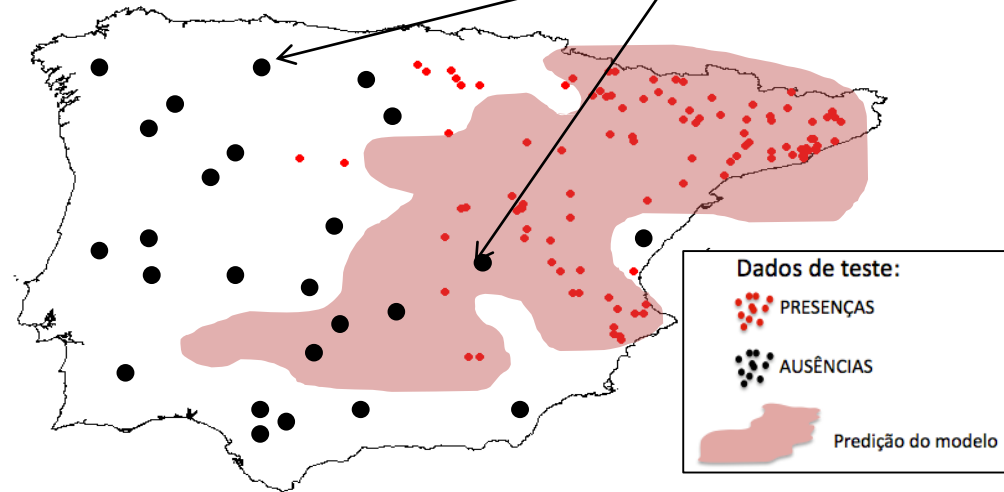
Sensitivity $\rightarrow \frac{a}{a + c}$

Specificity $\frac{d}{b + d}$

Medindo o ajuste do modelo:

Especificidade: $\frac{\text{ausências corretas}}{\text{Total de ausências}}$

	Presença	Ausência
Presença	a	b
Ausência	c	d



$$\text{Sensitivity} = \frac{a}{a + c}$$

$$\text{Specificity} \rightarrow \frac{d}{b + d}$$

Medindo o ajuste do modelo:

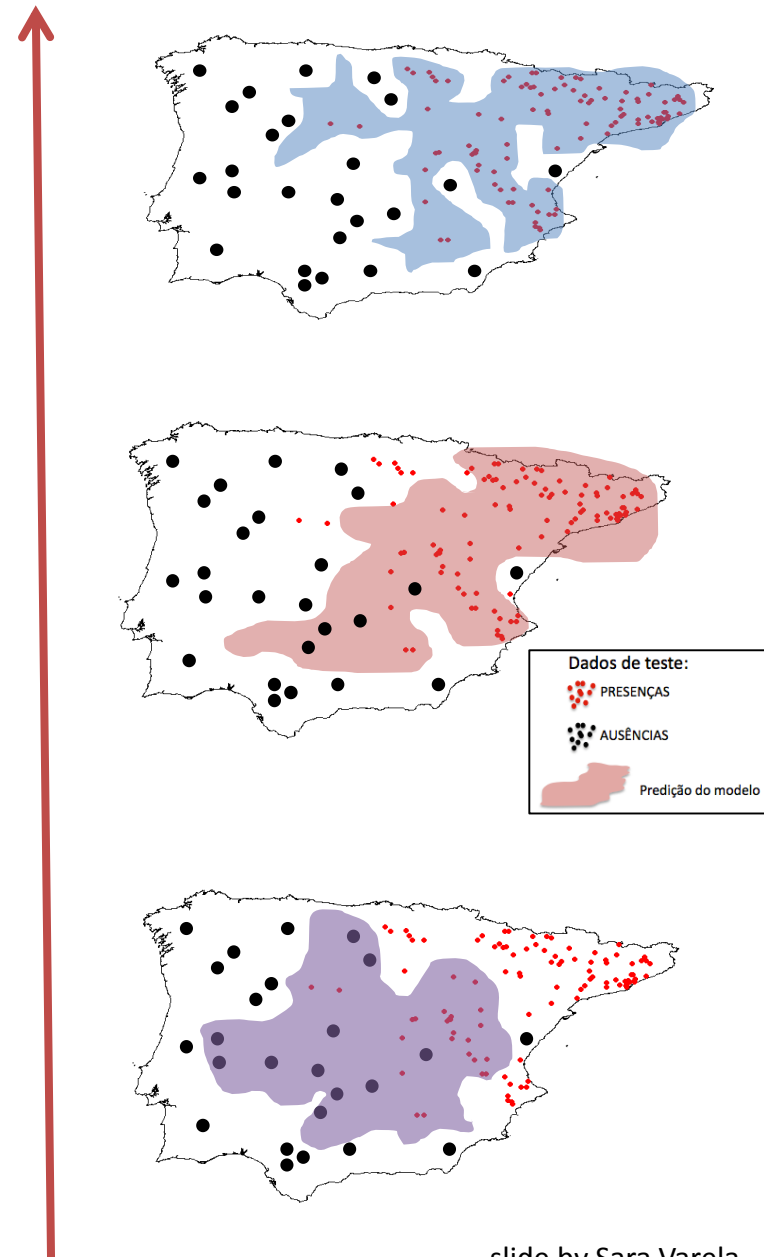
Sensitividade: porcentagem de predições de presenças corretas

Especificidade: porcentagem de predições de ausências corretas

$$\text{Sensitivity} = \frac{a}{a + c}$$

$$\text{Specificity} = \frac{d}{b + d}$$

		Validation data set	
		Presence	Absence
Model	Presence	<i>a</i>	<i>b</i>
	Absence	<i>c</i>	<i>d</i>


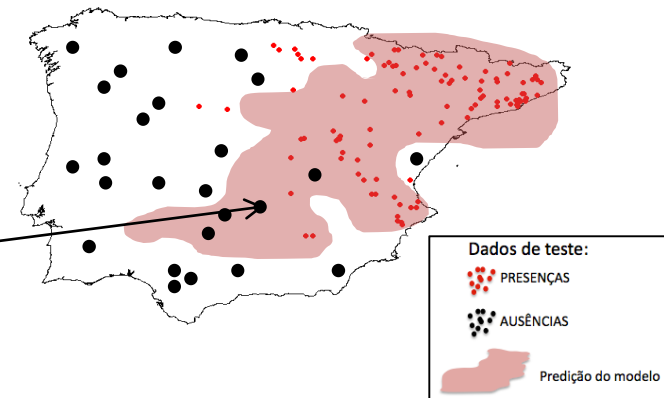


Medindo erros (failure):

Erro tipo I = falso positivo (FP)= **Comissão**

$$\text{comissão} = b/(b+d)$$

Validation data set			
		Presence	Absence
Model	Presence	<i>a</i>	<i>b</i>
	Absence	<i>c</i>	<i>d</i>


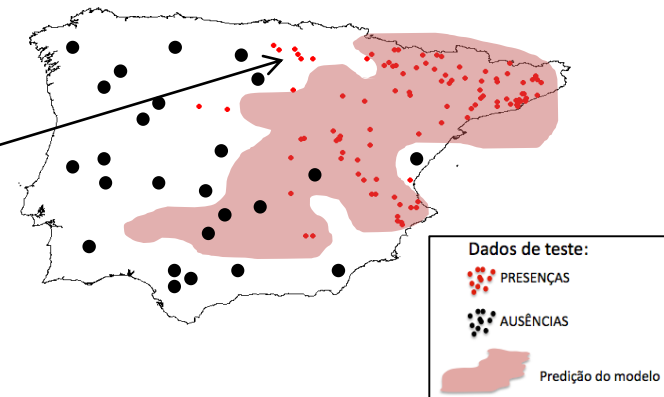


Medindo erros(failure):

Erro tipo II= Falso negativo (FN)= **omissão**

$$\text{omissão} = c/(a+c)$$

		Validation data set	
		Presence	Absence
Model	Presence	<i>a</i>	<i>b</i>
	Absence	<i>c</i>	<i>d</i>


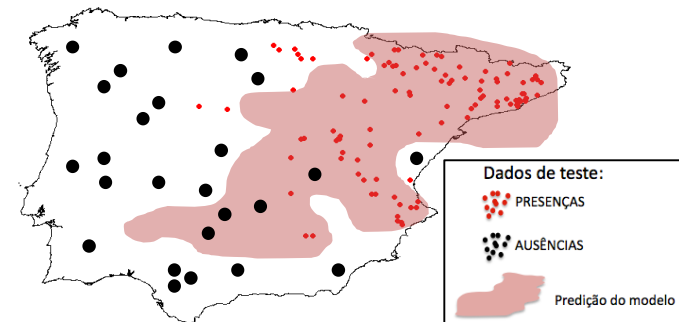



Medindo erros (failure):

Erro tipo I = falso positivo = comissão

Erro tipo II = falso negativo = omissão

		Validation data set	
		Presence	Absence
Model	Presence	<i>a</i>	<i>b</i>
	Absence	<i>c</i>	<i>d</i>



		Validation data set	
		Presence	Absence
Model	Presence	<i>a</i>	<i>b</i>
	Absence	<i>c</i>	<i>d</i>

- Sensitivity = $a/(a+c)$ = success in the 1s
 - Omission = $c/(a+c)$ = error in the 1s
 - Specificity = $d/(b+d)$ = success in the 0s
 - Commission = $b/(b+d)$ = error in the 0s
- Omission = 1 - sensitivity
 - Commission = 1 - specificity

		Validation data set	
		Presence	Absence
Model	Presence	<i>a</i>	<i>b</i>
	Absence	<i>c</i>	<i>d</i>

Measure	Formula
Overall accuracy	$\frac{a + d}{n}$
Sensitivity	$\frac{a}{a + c}$
Specificity	$\frac{d}{b + d}$

		Validation data set	
		Presence	Absence
Model	Presence	a	b
	Absence	c	d

Measure	Formula
Overall accuracy	$\frac{a + d}{n}$
Sensitivity	$\frac{a}{a + c}$
Specificity	$\frac{d}{b + d}$
Kappa statistic	<div> <div>Presenças</div> <div>Ausências</div> </div> $\left(\frac{a + d}{n} \right) - \frac{(a + b)(a + c) + (c + d)(d + b)}{n^2}$
	$1 - \frac{(a + b)(a + c) + (c + d)(d + b)}{n^2}$

Kappa

**Corrige o nível de sucesso do modelo em comparação com aleatório
(Existe um nível de sucesso esperado simplesmente por acaso).**

Kappa varia de -1 a 1

**1 significa que o modelo é perfeito.
0 significa que o modelo não difere de modelos aleatórios**

		Validation data set	
		Presence	Absence
Model	Presence	<i>a</i>	<i>b</i>
	Absence	<i>c</i>	<i>d</i>

Measure	Formula
Overall accuracy	$\frac{a + d}{n}$
Sensitivity	$\frac{a}{a + c}$
Specificity	$\frac{d}{b + d}$
Kappa statistic	$\frac{\left(\frac{a + d}{n}\right) - \frac{(a + b)(a + c) + (c + d)(d + b)}{n^2}}{1 - \frac{(a + b)(a + c) + (c + d)(d + b)}{n^2}}$

➡ TSS sensitivity + specificity – 1

True skill statistic (TSS)

Numero de sucesos menos o número de sucesos aleatórios

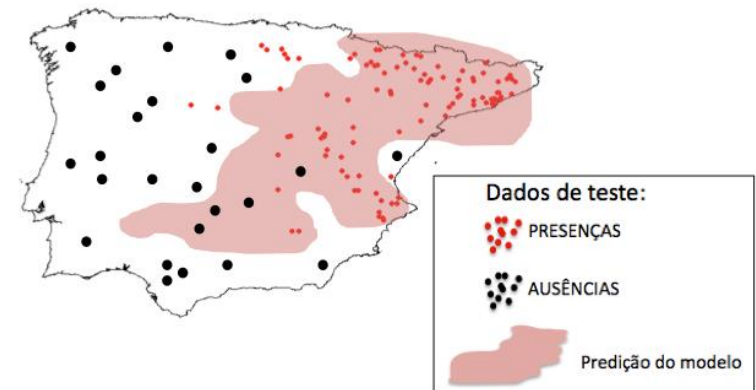
Varia de -1 to 1. Valores próximos a 0 modelos não diferentes do aleatórios.

$$\text{TSS} = \text{sensitivity} + \text{specificity} - 1$$

Todos os índices são baseados em **sucessos** e **erros** das predições.


Avaliação binária!!!

		Validation data set	
		Presence	Absence
Model	Presence	<i>a</i>	<i>b</i>
	Absence	<i>c</i>	<i>d</i>



Entretanto...

os outputs dos modelos são contínuos....







Assim, precisamos converter mapas contínuos em binários....

slide by Sara Varela


Charles University – Czech Republic

Para isso.....**threshold**






Threshold
0



0.4



0.6









0.8








1




Qual o threshold apropriado??




Zero omissão



Zero omissão




Predict correctly
all the presences
(Zero omissão)




Maximize
sensitivity + specificity


Qual desses criterios de threshols É o melhor?




Minha recomendação.....



Maximize
sensit. + specif.




Não erra na predição
de acertos.
(Zero omissão)



...o Valor do *threshold* varia com o background




Maximize
sensit. + specif.



Does not fail in
predicting
presences
(Zero omissão)

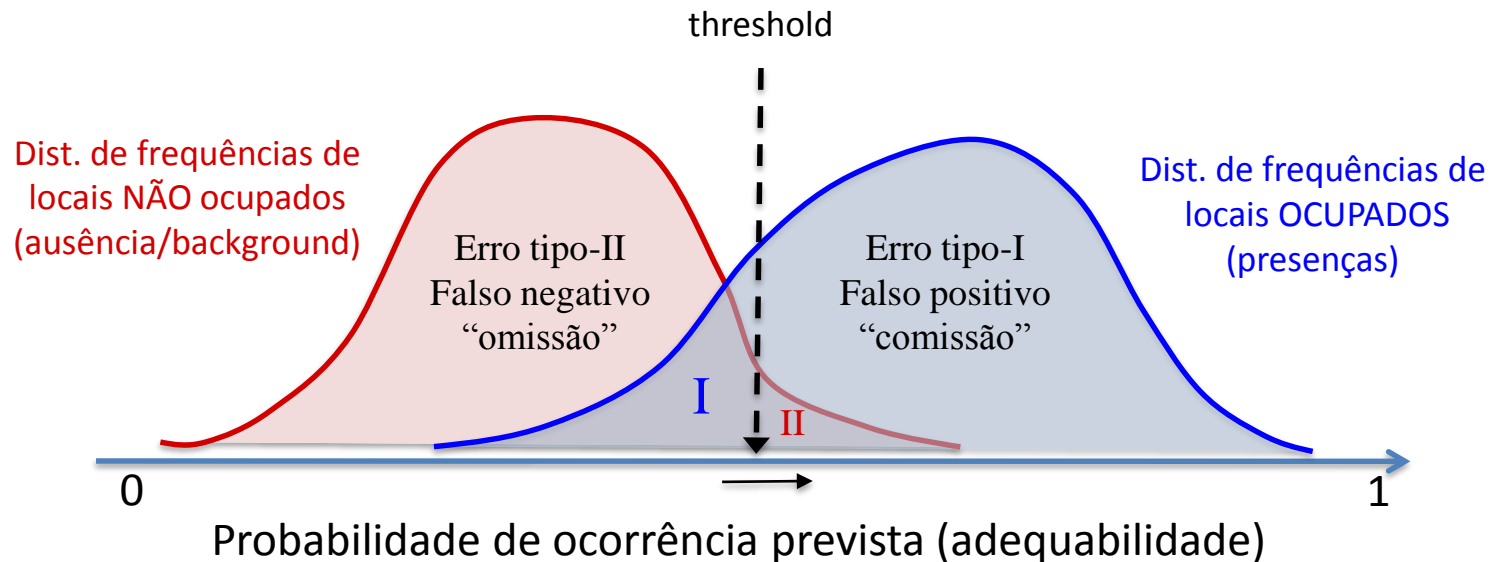
Considerações sobre as métricas dependentes de *thresholds*

- Aumentando o erro de **comissão**, diminui-se o erro de **omissão** e vice-versa;
- O *threshold* escolhido deve **balancear** os erros de omissão e comissão de acordo com o objetivo do estudo;




Considerações sobre as métricas dependentes de *thresholds*

- Aumentando o erro de comissão, diminui-se o erro de omissão e vice-versa;
- O *threshold* escolhido deve **balancear**, então, os erros de omissão e comissão de acordo com o objetivo do estudo;



Considerações sobre as métricas dependentes de *thresholds*

- Aumentando o erro de comissão, diminui-se o erro de omissão e vice-versa;
- O *threshold* escolhido deve **balancear**, então, os erros de omissão e comissão de acordo com o objetivo do estudo;



Considerações sobre as métricas dependentes de *thresholds*

- Aumentando o erro de comissão, diminui-se o erro de omissão e vice-versa;
- O *threshold* escolhido deve balancear, então, os erros de omissão e comissão de acordo com o objetivo do estudo;
- Para montar a matriz de confusão, necessita-se de **dados de ausência** das espécies, os quais nem sempre são possíveis (e.g. espécies extintas);
- Dados de **pseudo-ausência** geram problema quanto ao tamanho da área background;
- A matriz de confusão não utiliza toda a informação gerada pelos modelos (apenas a **classificação binária**), varia com o *threshold* escolhido e muitas vezes sua escolha é subjetiva.

Mas existem métricas independentes de *thresholds*...

ROC-AUC


- Calcula o ajuste do modelo independente do threshold.
- **ROC** = Receiver Operating Characteristic
 - Curva definido pelos valores de sucesso do modelo em todos os threshold.
- **AUC** = Area Under Curve
 - Integral da curva ROC (values from 0 to 1)

ROC-AUC

		Validation data set	
		Presence	Absence
Model	Presence	a	b
	Absence	c	d

Sensitivity	$\frac{a}{a + c}$
Specificity	$\frac{d}{b + d}$

PPV:
acertos em 1s
= $a/(c+a)$



1 – Especificidade
Comissão (FPF):
Erros em 0s
= $b/(b+d)$


ROC-AUC

		Validation data set	
		Presence	Absence
Model	Presence	a	b
	Absence	c	d


Sensitivity	$\frac{a}{a + c}$
Specificity	$\frac{d}{b + d}$

PPV:
acertos em 1s
= $a/(c+a)$

Escolhe-se diferentes *thresholds* ao longo do gradiente de adequabilidade e calcula-se Especificidade/Sensibilidade e plota seus pontos no gráfico ao lado.



1 – Especificidade
Comissão (PFP):
Erros em 0s
= $b/(b+d)$


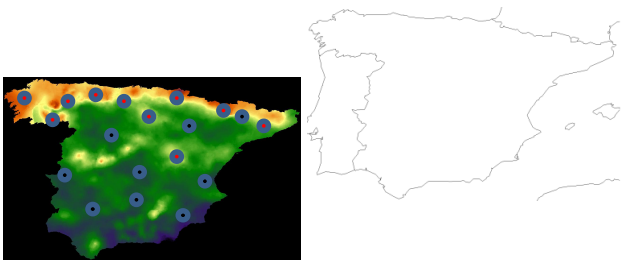


ROC-AUC


		Validation data set	
		Presence	Absence
Model	Presence	a	b
	Absence	c	d

Sensitivity	$\frac{a}{a + c}$
Specificity	$\frac{d}{b + d}$

PPV:
acertos em 1s
 $= a/(c+a)$



e.g. tsh = 1






1 – Especificidade
Comissão (PFP):
Erros em 0s
 $= b/(b+d)$

ROC-AUC

		Validation data set	
		Presence	Absence
Model	Presence	a	b
	Absence	c	d

Sensitivity	$\frac{a}{a+c}$
Specificity	$\frac{d}{b+d}$




PPV:
acertos em 1s
 $= a/(c+a)$



ROC-AUC

		Validation data set	
		Presence	Absence
Model	Presence	<i>a</i>	<i>b</i>
	Absence	<i>c</i>	<i>d</i>

PPV:
acertos em 1s
 $= a/(c+a)$






1 – Especificidade
Comissão (PFP):
Erros em 0s
 $= b/(b+d)$

ROC-AUC

		Validation data set	
		Presence	Absence
Model	Presence	a	b
	Absence	c	d

PPV:
acertos em 1s
 $= a/(c+a)$






1 – Especificidade
Comissão (PFP):
Erros em 0s
 $= b/(b+d)$

ROC-AUC

		Validation data set	
		Presence	Absence
Model	Presence	a	b
	Absence	c	d

PPV:
acertos em 1s
 $= a/(c+a)$






1 – Especificidade
Comissão (PFP):
Erros em 0s
 $= b/(b+d)$

ROC-AUC

		Validation data set	
		Presence	Absence
Model	Presence	<i>a</i>	<i>b</i>
	Absence	<i>c</i>	<i>d</i>

PPV:
acertos em 1s
 $= a/(c+a)$






1 – Especificidade
Comissão (PFP):
Erros em 0s
 $= b/(b+d)$

ROC-AUC

		Validation data set	
		Presence	Absence
Model	Presence	a	b
	Absence	c	d

PPV:
acertos em 1s
 $= a/(c+a)$






1 – Especificidade
Comissão (PFP):
Erros em 0s
 $= b/(b+d)$

ROC-AUC

		Validation data set	
		Presence	Absence
Model	Presence	<i>a</i>	<i>b</i>
	Absence	<i>c</i>	<i>d</i>

PPV:
acertos em 1s
 $= a/(c+a)$




1 – Especificidade
Comissão (PFP):
Erros em 0s
 $= b/(b+d)$

ROC-AUC

		Validation data set	
		Presence	Absence
Model	Presence	<i>a</i>	<i>b</i>
	Absence	<i>c</i>	<i>d</i>

PPV:
acertos em 1s
= $a/(c+a)$




1 – Especificidade
Comissão (PFP):
Erros em 0s
= $b/(b+d)$

ROC-AUC

Validation data set



Model		Validation data set	
		Presence	Absence
	Presence	a	b
	Absence	c	d

PPV:
acertos em 1s
 $= a/(c+a)$



1 – Especificidade
Comissão (PFP):
Erros em 0s
 $= b/(b+d)$

O Que significa o índice AUC?





AUC é uma medida de performance do classificador (modelos);

Um AUC = 0.7 indica que o modelo acerta a classificação de presenças e ausências das espécies em 70% dos casos (do dados de treino);

O Que significa o índice AUC?


PPV:
acertos em 1s
= $a/(c+a)$



Por exemplo, inúmeros pares de presenças e ausências a partir dos dados de teste, o modelo acertaria maior valor de adequabilidade para as presenças (em relação às suas respectivas ausências) para 70% dos pares.

O Que significa o índice AUC?

PPV:
acertos em 1s
 $= a/(c+a)$




Um AUC=0.5 indica que o modelo acerta apenas em 50% dos casos (aleatório).

1 - Especificidade
Comissão (PFP):
Erros em 0s
 $= b/(b+d)$

O Que significa o índice AUC?


PPV:
acertos em 1s
 $= a/(c+a)$



Measuring the Accuracy of Diagnostic Systems

JOHN A. SWETS

$AUC > 0.9$ – bom desempenho




4

Quantitative Methods for Modeling Species Habitat: Comparative Performance and an Application to Australian Plants

Jane Elith

$AUC > 0.7$ – modelos úteis

Predições ENMs



amostragem
Jackknife

registro	predição	área	Distribuição binomial cumulativa
Lagoa Santa	1	0,87	
Taima-Taima	1	0,76	
Cueva Tixi	1	0,58	
Furna Estrago	0	0,39	

Taxa de sucesso = 3/4

p-valor = 0.58

predição modelo = predição aleatória

Jackknife:

um método de avaliação para poucos pontos de ocorrência.

Journal of Biogeography (J. Biogeogr.) (2007) 34, 102–117



Predicting species distributions from small numbers of occurrence records: a test case using cryptic geckos in Madagascar

Richard G. Pearson^{1*}, Christopher J. Raxworthy², Miguel Nakamura³ and A. Townsend Peterson⁴

Sucesso/fracasso
(1/0)

Área predita
(prob. de ocorrência)

$$D = \sum X_i(1 - P_i).$$

Avaliação vs. Validação

uma questão conceitual

Dados **não-independentes**:

- Partição treino/teste dos dados disponíveis;
- Dados de teste contemporâneos aos de treino;
- avalia-se o modelo com dados teste do **mesmo período/região** que os dados treino.

Dados **independentes**:

- avalia-se o modelo com dados teste de **outro período/região** que os dados treino;
- dados fósseis, regiões invadidas, outro indicador (*proxy*);

OBRIGADO!

Thadeu Sobral-Souza

Unesp – Rio Claro

thadeusobral@gmail.com